

Tarea Corta N°4

Estudiante [Andreas Laffert](#)

miércoles, 23 de octubre de 2024

En esta tarea usarás los datos de una encuesta realizada por FLACSO/Chile en Abril y Mayo de 1988 sobre intención de voto en el plebiscito de 1989, junto con otras variables socio-demográficas.

En particular, trabajarás con el siguiente modelo de regresión logística que estima la probabilidad de votar SI en función de los ingresos, género (M=Hombre, F=Mujer) y el apoyo al status-quo (valores más altos indican mayor apoyo al régimen de Pinochet).

```
modelo_1 <- glm(vote ~ income + sex*statusquo, family=binomial, data = datos_chile)
summary(modelo_1)
```

Call:

```
glm(formula = vote ~ income + sex * statusquo, family = binomial,
     data = datos_chile)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-3.2341	-0.2763	-0.1517	0.1967	2.8455

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	0.798747728	0.176250484	4.532	0.00000585	***
income	-0.000006240	0.000002414	-2.585	0.00974	**
sexM	-0.647235203	0.206756852	-3.130	0.00175	**
statusquo	3.242978737	0.215435486	15.053	< 0.00000000000000002	***
sexM:statusquo	-0.046494020	0.290076049	-0.160	0.87266	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 2360.29 on 1702 degrees of freedom
Residual deviance: 719.26 on 1698 degrees of freedom
AIC: 729.26

Number of Fisher Scoring iterations: 6

Preguntas:

1. Calcula la probabilidad de votar por el SI para hombres y mujeres cuyos ingresos y apoyo al status-quo se encuentran en el decil 10 (10% superior) de cada variable.

Implementación en R:

```
decil_10_income <- quantile(datos_chile$income, 0.9, na.rm = TRUE)
decil_10_statusquo <- quantile(datos_chile$statusquo, 0.9, na.rm = TRUE)

newdata <- data.frame(
  income = decil_10_income,
  statusquo = decil_10_statusquo,
  sex = c("F", "M")
)

predictions(modelo_1, conf_level = .95, newdata = newdata) %>%
  as_tibble() %>%
  dplyr::mutate(
    genero = if_else(rowid == 1, "F", "M"),
    estimate = round(estimate, 3),
    ic_95 = paste0("[", round(conf.low, 3), ",",
                    round(conf.high, 3), "]"),
    stars = gtools::stars.pval(p.value),
    p_value = case_when(
      p.value < 0.05 & p.value > 0.01 ~ "< 0.05",
      p.value < 0.01 & p.value > 0.001 ~ "< 0.01",
      p.value < 0.001 ~ "< 0.001",
      TRUE ~ ""
    ),
    p_value = paste0(p_value, stars)
  ) %>%
  dplyr::select(genero, income, statusquo, estimate, p_value, ic_95) %>%
```

Tabla 1: Probabilidades predichas de votar SI para hombres y mujeres cuyos ingresos y apoyo al statusquo se encuentran en el 10% superior

Género	Ingresos	Statusquo	Estimado	p-value	IC 95%
F	75000	1.456132	0.994	< 0.001***	[0.986,0.997]
M	75000	1.456132	0.987	< 0.001***	[0.975,0.993]

```
kableExtra::kable(format = "latex",
  col.names = c("Género", "Ingresos", "Statusquo",
    "Estimado", "p-value", "IC 95%"),
  booktabs = T,
  align = 'c') %>%
kableExtra::kable_styling(position = "center",
  bootstrap_options = c("striped", "hover",
    "condensed", "responsive"),
  full_width = F) %>%
column_spec(1, width = "2cm",) %>%
row_spec(0, bold = T)
```

En la Tabla 1 se presentan las probabilidades predichas de votar “Sí” en el plebiscito, estimadas para un hombre y una mujer cuyos ingresos y apoyo al status quo se encuentran en el decil superior (10%) de cada variable. Los resultados muestran que la probabilidad estimada de votar “Sí” es ligeramente mayor para las mujeres (99.4%) que para los hombres (98.7%).

Ambas estimaciones son estadísticamente significativas ($p < 0.001$), lo que sugiere que, bajo las condiciones de ingresos elevados y fuerte apoyo al status quo, tanto hombres como mujeres tienen una probabilidad muy alta de votar “Sí”. Sin embargo, la diferencia entre sexos en términos de probabilidad predicha no es muy pronunciada, lo cual es consistente con la interacción no significativa entre género y apoyo al status quo en el modelo 1 ($p = 0.873$). Esto indica que el efecto del apoyo al status quo sobre la probabilidad de votar “Sí” es similar para ambos géneros.

Además, los intervalos de confianza al 95% para las estimaciones de probabilidad son muy estrechos y se solapan: para las mujeres, el intervalo se encuentra entre 98.6% y 99.7%, mientras que para los hombres, el intervalo está entre 97.5% y 99.3%.

2. Usa el método de Bootstrap para crear un intervalo de confianza al 98% para la diferencia en la probabilidad de votar por el SI entre hombres y mujeres cuyos ingresos y apoyo al statusquo se encuentran en el decil 10 (10% superior) de cada variable. ¿Existe una diferencia estadísticamente significativa en la probabilidad de votar por el SI de ambos grupos?

Implementación en R:

```

# Inicializar el vector para almacenar resultados de Bootstrap
results <- NULL

# Iterar 1000 veces para realizar el Bootstrap
for (i in 1:1000) {

  # Realizar una muestra aleatoria con reemplazo del mismo tamaño que el conjunto original
  data_bs <- sample_n(datos_chile, size = nrow(datos_chile), replace = T)

  # Ajustar un modelo de regresión logística con las variables deseadas
  model <- glm(vote ~ income + sex*statusquo, family = "binomial", data = data_bs)

  # Crear nuevos puntos de datos para la predicción usando expand.grid()
  newx_f <- expand.grid(sex = "F", income = 75000, statusquo = 1.46)
  newx_m <- expand.grid(sex = "M", income = 75000, statusquo = 1.46)

  # Realizar las predicciones para mujeres y hombres
  pred_f <- predict(model, newdata = newx_f, type = "response")
  pred_m <- predict(model, newdata = newx_m, type = "response")

  # Calcular la diferencia entre las probabilidades predichas
  diff_p <- pred_m - pred_f

  # Almacenar el resultado en el vector de resultados
  results[i] <- diff_p
}

ci_98 <- quantile(results, probs = c(0.01, 0.99))
low_98 <- round(ci_98[1], 3)
high_98 <- round(ci_98[2], 3)

data.frame(beta = results) %>%
  ggplot(aes(x = beta)) +
  geom_histogram(color = "white", bins = 10,
                 boundary = 0, fill = "#483d8b") +
  scale_y_continuous(n.breaks = 10) +
  geom_vline(xintercept = ci_98[1], color = "#e34e0e", linetype = "dashed", linewidth = 2) +
  geom_vline(xintercept = ci_98[2], color = "#e34e0e", linetype = "dashed", linewidth = 2)


```

```

annotate("text", x = ci_98[1], y = 260, label = round(ci_98[1], 3), color = "#e34e0e",
annotate("text", x = ci_98[2], y = 260, label = round(ci_98[2], 3), color = "#e34e0e",
labs(y = "Frecuencia",
     x = "Diferencia en probabilidades",
     caption = "Fuente: Elaboración propia en base a Datos Chile
     Nota: IC al 98%") +
theme_ggdist()

```

Figura 1: Distribución de la diferencia en probabilidades predichas



Fuente: Elaboración propia en base a Datos Chile
Nota: IC al 98%

En la Figura 1 se presenta la distribución de la diferencia en las probabilidades predichas de votar “Sí” en el plebiscito, estimadas para un hombre y una mujer cuyos ingresos y apoyo al status quo se sitúan en el decil superior (10%) de cada variable, utilizando un intervalo de confianza del 98%. Los resultados muestran que, con un 98% de confianza, no se puede concluir que exista una diferencia estadísticamente significativa en la probabilidad de votar “Sí” entre hombres y mujeres en estas condiciones (IC = [-0.02; 0.004]). Esto indica que las diferencias observadas entre los géneros podrían ser atribuibles al azar.

- Además del modelo_1 usado anteriormente, crea un modelo más complejo usando la información disponible en la base de datos. Llama a este modelo, modelo_2.

Implementación en R:

- Usando un umbral de 0.5, crea una clasificación de la intención de voto de los individuos de la muestra de acuerdo a ambos modelos y compara la “confusion matrix” de ambos.

Tabla 2: Modelos de regresión logística para voto en plebiscito

```
modelo_2 <- glm(vote ~ income + education + sex + statusquo + age, family=binomial, data=
texreg::texreg(
  l = list(modelo_1, modelo_2),
  caption = NULL,
  stars = c(0.05, 0.01, 0.001),
  custom.note = "%stars.",
  custom.model.names = c("Modelo 1", "Modelo 2"),
  leading.zero = TRUE,
  use.packages = FALSE,
  booktabs = TRUE,
  scalebox = 1
)
```

	Modelo 1	Modelo 2
(Intercept)	0.80*** (0.18)	1.01** (0.38)
income	−0.00** (0.00)	−0.00 (0.00)
sexM	−0.65** (0.21)	−0.57** (0.20)
statusquo	3.24*** (0.22)	3.18*** (0.15)
sexM:statusquo	−0.05 (0.29)	
educationPS		−0.96** (0.34)
educationS		−0.63** (0.24)
age		0.00 (0.01)
AIC	729.26	721.52
BIC	756.46	759.60
Log Likelihood	−359.63	−353.76
Deviance	719.26	707.52
Num. obs.	1703	1703

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$.

Tabla 3

Se evaluarán dos modelos de regresión logística utilizados para predecir la intención de voto “Sí” en el plebiscito. El Modelo 1 corresponde a un que estima la probabilidad de voto a partir del ingreso, el género, el apoyo al status quo y una interacción entre estas dos últimas covariables. El Modelo 2 también es un modelo estima la probabilidad de voto a partir del ingreso, el género, el apoyo al status quo, el nivel educacional y la edad. En la Tabla 2 se muestran los resultados de estos modelos.

Implementación en R para el modelo_1:

```
p_hat_1 <- predict(modelo_1, type = "response")
y_hat_1 <- if_else(p_hat_1 > 0.5,1,0)

#confussion matrix
conf_mat_1 <- confusionMatrix(factor(y_hat_1), factor(modelo_1$model$vote), dnn = c("Pre", "True"))

conf_mat_1
```

Confusion Matrix and Statistics

	True value	
Prediction	0	1
0	810	69
1	57	767

Accuracy : 0.926
 95% CI : (0.9125, 0.938)
 No Information Rate : 0.5091
 P-Value [Acc > NIR] : <0.00000000000000002

Kappa : 0.8519

McNemar's Test P-Value : 0.3271

Sensitivity : 0.9343
 Specificity : 0.9175
 Pos Pred Value : 0.9215
 Neg Pred Value : 0.9308
 Prevalence : 0.5091
 Detection Rate : 0.4756
 Detection Prevalence : 0.5161
 Balanced Accuracy : 0.9259

'Positive' Class : 0

Implementación en R para el modelo_2:

```
p_hat_2 <- predict(modelo_2, type = "response")
y_hat_2 <- if_else(p_hat_2 > 0.5, 1, 0)

#confussion matrix
conf_mat_2 <- confusionMatrix(factor(y_hat_2), factor(modelo_2$model$vote), dnn = c("Pre", "Actual"))

conf_mat_2
```

Confusion Matrix and Statistics

	True value	
Prediction	0	1
0	808	64
1	59	772

Accuracy : 0.9278
95% CI : (0.9144, 0.9396)
No Information Rate : 0.5091
P-Value [Acc > NIR] : <0.0000000000000002

Kappa : 0.8555

Mcnemar's Test P-Value : 0.7183

Sensitivity : 0.9319
Specificity : 0.9234
Pos Pred Value : 0.9266
Neg Pred Value : 0.9290
Prevalence : 0.5091
Detection Rate : 0.4745
Detection Prevalence : 0.5120
Balanced Accuracy : 0.9277

'Positive' Class : 0

Métricas de comparación entre modelos

Accuracy

$$\text{Accuracy}_{M1} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{767 + 810}{767 + 810 + 69 + 57} \approx 0.926$$

$$\text{Accuracy}_{M2} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{772 + 808}{772 + 808 + 64 + 59} \approx 0.9278$$

Misclassification Rate

$$\text{Misclassification Rate}_{M1} = \frac{FP + FN}{TP + TN + FP + FN} = \frac{69 + 57}{767 + 810 + 69 + 57} \approx 0.074$$

$$\text{Misclassification Rate}_{M2} = \frac{FP + FN}{TP + TN + FP + FN} = \frac{64 + 59}{772 + 808 + 64 + 59} \approx 0.0722$$

True Positive Rate (Sensitivity)

$$\text{Sensitivity}_{M1} = \frac{TP}{TP + FN} = \frac{767}{767 + 57} \approx 0.934$$

$$\text{Sensitivity}_{M2} = \frac{TP}{TP + FN} = \frac{772}{772 + 59} \approx 0.9319$$

False Positive Rate

$$\text{False Positive Rate}_{M1} = \frac{FP}{FP + TN} = \frac{69}{69 + 810} \approx 0.077$$

$$\text{False Positive Rate}_{M2} = \frac{FP}{FP + TN} = \frac{64}{64 + 808} \approx 0.0735$$

True Negative Rate (Specificity)

$$\text{Specificity}_{M1} = \frac{TN}{FP + TN} = \frac{810}{69 + 810} \approx 0.917$$

$$\text{Specificity}_{M2} = \frac{TN}{FP + TN} = \frac{808}{64 + 808} \approx 0.9234$$

Precision

$$\text{Precision}_{M1} = \frac{TP}{TP + FP} = \frac{767}{767 + 69} \approx 0.921$$

$$\text{Precision}_{M2} = \frac{TP}{TP + FP} = \frac{772}{772 + 64} \approx 0.9266$$

Prevalence

$$\text{Prevalence}_{M1} = \frac{TP + FN}{TP + TN + FP + FN} = \frac{767 + 57}{767 + 810 + 69 + 57} \approx 0.509$$

$$\text{Prevalence}_{M2} = \frac{TP + FN}{TP + TN + FP + FN} = \frac{772 + 59}{772 + 808 + 64 + 59} \approx 0.509$$

Con todo, ambos modelos muestran un rendimiento robusto en la clasificación de la intención de voto, con el Modelo 2 presentando una leve ventaja en términos de exactitud, tasa de clasificación incorrecta, especificidad y precisión. Sin embargo, el Modelo 1 tiene una ligera ventaja en sensibilidad, lo que sugiere que podría ser más adecuado en contextos donde es crucial minimizar los falsos negativos.

- b) Usa 10-fold cross-validation (paquete caret en R) para evaluar qué modelo predice mejor la intención de voto de los individuos encuestados. (caret usa un umbral de 0.5 para la clasificación).

Implementación en R:

```
# especifica tipo de cross-validation
ctrl <- trainControl(method = "repeatedcv", number = 10, savePredictions = TRUE)

# cross-valida M0
cv_logit_modelo_1 <- train(factor(vote) ~ income + factor(sex)*statusquo, data=datos_c

# cross-valida M1
cv_logit_modelo_2 <- train(factor(vote) ~ income + factor(education) + factor(sex) + sta

confusionMatrix(cv_logit_modelo_1)
```

Cross-Validated (10 fold, repeated 1 times) Confusion Matrix

(entries are percentual average cell counts across resamples)

Reference

Prediction	0	1
0	47.5	4.1
1	3.4	45.0

Accuracy (average) : 0.9254

```
confusionMatrix(cv_logit_modelo_2)
```

Cross-Validated (10 fold, repeated 1 times) Confusion Matrix

(entries are percentual average cell counts across resamples)

	Reference	
Prediction	0	1
0	47.3	3.8
1	3.6	45.3

Accuracy (average) : 0.9266

Por un lado, los resultados de la matriz de confusión del Modelo 1 sugieren que este modelo predice correctamente el 47.4% de los casos negativos (0) y el 45.0% de los casos positivos (1). Además, hay un 4.1% de casos positivos que fueron clasificados incorrectamente como negativos (falsos negativos) y un 3.5% de casos negativos que fueron clasificados incorrectamente como positivos (falsos positivos). La precisión promedio del modelo es del 92.48%, lo que indica un buen rendimiento.

Por otro lado, los resultados de la matriz de confusión del Modelo 2 sugieren que este modelo predice correctamente el 47.3% de los casos negativos y el 45.2% de los casos positivos. Adicionalmente, el 3.9% de los casos positivos fueron clasificados incorrectamente como negativos (falsos negativos) y el 3.6% de los casos negativos fueron clasificados incorrectamente como positivos (falsos positivos). La precisión promedio del modelo es del 92.54%, que es ligeramente superior a la del Modelo 1.

En definitiva, ambos modelos muestran un rendimiento alto en la clasificación de la intención de voto, con el Modelo 2 logrando una precisión promedio ligeramente mejor (92.54% frente a un 92.48%). Ambos modelos presentan tasas similares de falsos positivos y falsos negativos, lo que indica que las diferencias en precisión son mínimas, pero el Modelo 2 muestra un mejor manejo de los casos positivos.

Código de R

```
knitr::opts_chunk$set(echo = F,
                      warning = F,
                      error = F,
                      message = F)
if (! require("pacman")) install.packages("pacman")

pacman::p_load(tidyverse,
              rio,
              here,
              ggdist,
              caret,
              carData,
              modelr,
              easystats,
              marginaleffects,
              kableExtra,
              gtools,
              texreg)

options(scipen=999)
rm(list = ls())
data("Chile")
datos_chile <- Chile
datos_chile <- datos_chile %>% mutate(vote = case_when(vote=="Y" ~ 1, vote=="N" ~ 0)) %>%
datos_chile %>% glimpse()

modelo_1 <- glm(vote ~ income + sex*statusquo, family=binomial, data = datos_chile)
summary(modelo_1)
decil_10_income <- quantile(datos_chile$income, 0.9, na.rm = TRUE)
decil_10_statusquo <- quantile(datos_chile$statusquo, 0.9, na.rm = TRUE)

newdata <- data.frame(
  income = decil_10_income,
  statusquo = decil_10_statusquo,
  sex = c("F", "M")
)
```

```

predictions(modelo_1, conf_level = .95, newdata = newdata) %>%
  as_tibble() %>%
  dplyr::mutate(
    genero = if_else(rowid == 1, "F", "M"),
    estimate = round(estimate, 3),
    ic_95 = paste0("[", round(conf.low, 3), ",",
                     round(conf.high, 3), "]"),
    stars = gtools::stars.pval(p.value),
    p_value = case_when(
      p.value < 0.05 & p.value > 0.01 ~ "< 0.05",
      p.value < 0.01 & p.value > 0.001 ~ "< 0.01",
      p.value < 0.001 ~ "< 0.001",
      TRUE ~ ""
    ),
    p_value = paste0(p_value, stars)
  ) %>%
  dplyr::select(genero, income, statusquo, estimate, p_value, ic_95) %>%
  kableExtra::kable(format = "latex",
                    col.names = c("Género", "Ingresos", "Statusquo",
                                   "Estimado", "p-value", "IC 95%"),
                    booktabs = T,
                    align = 'c') %>%
  kableExtra::kable_styling(position = "center",
                             bootstrap_options = c("striped", "hover",
                                                     "condensed", "responsive"),
                             full_width = F) %>%
  column_spec(1, width = "2cm",) %>%
  row_spec(0, bold = T)
# Inicializar el vector para almacenar resultados de Bootstrap
results <- NULL

# Iterar 1000 veces para realizar el Bootstrap
for (i in 1:1000) {

  # Realizar una muestra aleatoria con reemplazo del mismo tamaño que el conjunto original
  data_bs <- sample_n(datos_chile, size = nrow(datos_chile), replace = T)

  # Ajustar un modelo de regresión logística con las variables deseadas

```

```

model <- glm(vote ~ income + sex*statusquo, family = "binomial", data = data_bs)

# Crear nuevos puntos de datos para la predicción usando expand.grid()
newx_f <- expand.grid(sex = "F", income = 75000, statusquo = 1.46)
newx_m <- expand.grid(sex = "M", income = 75000, statusquo = 1.46)

# Realizar las predicciones para mujeres y hombres
pred_f <- predict(model, newdata = newx_f, type = "response")
pred_m <- predict(model, newdata = newx_m, type = "response")

# Calcular la diferencia entre las probabilidades predichas
diff_p <- pred_m - pred_f

# Almacenar el resultado en el vector de resultados
results[i] <- diff_p
}

ci_98 <- quantile(results, probs = c(0.01, 0.99))
low_98 <- round(ci_98[1], 3)
high_98 <- round(ci_98[2], 3)

data.frame(beta = results) %>%
  ggplot(aes(x = beta)) +
  geom_histogram(color = "white", bins = 10,
                 boundary = 0, fill = "#483d8b") +
  scale_y_continuous(n.breaks = 10) +
  geom_vline(xintercept = ci_98[1], color = "#e34e0e", linetype = "dashed", linewidth = 2) +
  geom_vline(xintercept = ci_98[2], color = "#e34e0e", linetype = "dashed", linewidth = 2) +
  annotate("text", x = ci_98[1], y = 260, label = round(ci_98[1], 3), color = "#e34e0e", size = 12) +
  annotate("text", x = ci_98[2], y = 260, label = round(ci_98[2], 3), color = "#e34e0e", size = 12) +
  labs(y = "Frecuencia",
       x = "Diferencia en probabilidades",
       caption = "Fuente: Elaboración propia en base a Datos Chile",
       text = "Nota: IC al 98%") +
  theme_ggdist()

modelo_2 <- glm(vote ~ income + education + sex + statusquo + age, family=binomial, data=

```

```

texreg::texreg(
  l = list(modelo_1, modelo_2),
  caption = NULL,
  stars = c(0.05, 0.01, 0.001),
  custom.note = "%stars.",
  custom.model.names = c("Modelo 1", "Modelo 2"),
  leading.zero = TRUE,
  use.packages = FALSE,
  booktabs = TRUE,
  scalebox = 1
)

p_hat_1 <- predict(modelo_1, type = "response")
y_hat_1 <- if_else(p_hat_1 > 0.5, 1, 0)

#confussion matrix
conf_mat_1 <- confusionMatrix(factor(y_hat_1), factor(modelo_1$model$vote), dnn = c("Pre

conf_mat_1
p_hat_2 <- predict(modelo_2, type = "response")
y_hat_2 <- if_else(p_hat_2 > 0.5, 1, 0)

#confussion matrix
conf_mat_2 <- confusionMatrix(factor(y_hat_2), factor(modelo_2$model$vote), dnn = c("Pre

conf_mat_2
# especifica tipo de cross-validation
ctrl <- trainControl(method = "repeatedcv", number = 10, savePredictions = TRUE)

# cross-valida M0
cv_logit_modelo_1 <- train(factor(vote) ~ income + factor(sex)*statusquo, data=datos_c

# cross-valida M1
cv_logit_modelo_2 <- train(factor(vote) ~ income + factor(education) + factor(sex) + sta

confusionMatrix(cv_logit_modelo_1)
confusionMatrix(cv_logit_modelo_2)

```